

Fusão Latente de Foundation Models para Predição Financeira Multimodal

Rodrigo Banin Ferraz de Camargo
Instituto de Computação – UNICAMP

Allan Mariano de Souza
Instituto de Computação – UNICAMP

Resumo

Esta proposta de Iniciação Científica tem como objetivo investigar arquiteturas multimodais para predição financeira baseadas na fusão latente entre Large Language Models (LLMs) e Foundation Models (FMs) para séries temporais. Enquanto séries temporais de mercado capturam dinâmicas quantitativas contínuas, textos financeiros (como notícias e comunicados sobre ativos) carregam informações semânticas sobre eventos e expectativas que influenciam diretamente o comportamento dos preços. Propõe-se um *framework* de fusão profunda e bidirecional de representações latentes, utilizando mecanismos de atenção cruzada, visando melhorar desempenho preditivo, explicabilidade e robustez sob *drift* temporal em cenários reais de mercado.

1 Introdução

O uso de aprendizado de máquina em finanças tem crescido com a disponibilidade de grandes volumes de dados e o avanço de modelos de alta capacidade. Problemas como predição de retornos e volatilidade são tradicionalmente abordados por meio de séries temporais numéricas, utilizando preços, volumes e indicadores técnicos.

Entretanto, o comportamento dos mercados também é fortemente influenciado por informações exógenas expressas em linguagem natural, como notícias e comunicados corporativos. Trabalhos recentes demonstram que modelos de linguagem são capazes de capturar sinais relevantes desses textos, muitas vezes antecipando movimentos de mercado [1].

Apesar desses avanços, grande parte das abordagens existentes trata texto e séries temporais de forma isolada ou por fusão superficial, limitando a modelagem de interações complexas entre eventos semânticos e dinâmicas quantitativas.

2 Problema e Lacuna

Modelos baseados exclusivamente em séries temporais apresentam limitações ao ignorar eventos externos que não se manifestam imediatamente nos preços. Por outro lado, abordagens puramente textuais não capturam a estrutura temporal e os regimes quantitativos do mercado. Técnicas comuns de fusão, como concatenação de *features* ou ensemble tardio, não permitem modelar dependências condicionais entre texto e dinâmica temporal.

A literatura recente carece de arquiteturas que realizem **fusão latente profunda e bidirecional** entre representações textuais e séries temporais contínuas, especialmente utilizando modelos fundacionais. Essa lacuna limita a capacidade dos modelos de capturar interações complexas entre narrativa financeira e comportamento quantitativo, além de reduzir a robustez a mudanças de regime e *drift* temporal.

3 Objetivos

Desenvolver e validar um *framework* multimodal de fusão latente entre LLMs e FMs para séries temporais financeiras, aplicado à predição de variáveis de mercado.

- Projetar um módulo de alinhamento e fusão latente para dados textuais e séries temporais.
- Avaliar o impacto da fusão profunda no desempenho preditivo em tarefas financeiras.
- Investigar mecanismos de explicabilidade baseados em atenção cruzada entre modalidades.
- Analisar a robustez do modelo frente a *drift* temporal e mudanças de regime de mercado.

4 Proposta

A Figura 1 apresenta a arquitetura geral do *framework* multimodal proposto para predição financeira, estruturada de forma a integrar, em nível latente, informações provenientes de séries temporais financeiras e de textos associados a ativos.




Figura 1: Arquitetura multimodal proposta com fusão latente entre texto e series temporais.

4.1 Módulo de Alinhamento e Fusão Latente

A principal contribuição deste trabalho está no módulo de alinhamento e fusão latente multimodal. Diferentemente de abordagens baseadas em concatenação de *features* ou fusão tardia, o *framework* proposto realiza uma integração profunda e bidirecional entre texto e séries temporais diretamente no espaço latente.

As representações extraídas dos modelos fundacionais unimodais são inicialmente projetadas para um espaço latente compartilhado. Em seguida, aplica-se um mecanismo de atenção cruzada, no qual cada modalidade passa a condicionar a interpretação da outra. Na atenção do domínio temporal para o textual, a representação temporal atua como *query*, enquanto a representação textual fornece *keys* e *values*, com pesos definidos por:

$$\text{Attn}_{ts \rightarrow txt} = \text{softmax} \left(\frac{Q_{ts} K_{txt}^T}{\sqrt{d_k}} \right)$$

Esse mecanismo permite ponderar dinamicamente informações textuais relevantes de acordo com o estado temporal do mercado, resultando em uma representação latente fundida que combina contexto semântico e dinâmica quantitativa.

4.2 Cabeça de Predição e Explicabilidade

A representação latente fundida é utilizada como entrada para uma cabeça de predição neural responsável por estimar variáveis financeiras futuras, como volatilidade ou direção de retorno. Ao operar sobre uma representação já integrada, a cabeça de predição explora diretamente as interações entre texto e séries temporais.

O uso explícito de atenção cruzada também confere interpretabilidade ao modelo. A análise dos pesos de atenção permite identificar quais eventos textuais e quais segmentos temporais tiveram maior influência nas predições, fornecendo evidências claras do processo decisório do modelo.

5 Conjuntos de Dados

Serão utilizados conjuntos de dados multimodais públicos amplamente reconhecidos na literatura:

- **FinMultiTime** [2]: dataset multimodal que alinha texto financeiro e séries temporais de ativos do SP 500, sendo particularmente adequado para avaliação de arquiteturas de fusão latente.

Esses datasets permitem validar a proposta em cenários realistas, com diversidade temporal e textual suficiente para análise de robustez e *drift*.


6 Metodologia e Cronograma

O projeto será desenvolvido ao longo de 12 meses, seguindo uma metodologia incremental organizada em etapas bem definidas. A seguir são descritas as principais atividades..

- **Atividade 1 – Fundamentação técnica e preparação do ambiente:** Estudo dos principais modelos fundacionais para séries temporais financeiras, LLMs aplicados a texto financeiro e arquiteturas multimodais baseadas em fusão latente e atenção cruzada. Paralelamente, será configurado o ambiente computacional necessário para experimentação.
- **Atividade 2 – Aquisição e pré-processamento dos dados multimodais:** Obtenção e organização de conjuntos de dados que integram séries temporais financeiras e textos. Os dados numéricos serão normalizados e organizados em janelas, enquanto os textos passarão por limpeza e alinhamento cronológico, gerando um conjunto de dados multimodal.
- **Atividade 3 – Implementação dos modelos unimodais de referência:** Desenvolvimento de modelos *baseline* baseados em séries temporais (como LSTM ou Transformers temporais) e modelos baseados apenas em texto, utilizando embeddings extraídos por LLMs. Esses modelos servirão como referência experimental para comparação.
- **Atividade 4 – Desenvolvimento do módulo de alinhamento e fusão latente:** Implementação do módulo central do projeto, responsável por alinhar e integrar representações textuais e temporais em um espaço latente compartilhado por meio de atenção cruzada bidirecional resultando em um módulo de fusão funcional e integrado à arquitetura completa.
- **Atividade 5 – Treinamento multimodal e ajuste de hiperparâmetros:** Treinamento do modelo multimodal, inicialmente focado no alinhamento entre modalidades e, em seguida, de forma *end-to-end*. Serão realizados ajustes de hiperparâmetros e monitoramento do desempenho, com o objetivo de obter um modelo estável.
- **Atividade 6 – Validação experimental e benchmarking:** Avaliação sistemática do modelo proposto em comparação com os modelos de referência, utilizando divisões cronológicas dos dados. Serão analisadas métricas de desempenho adequadas às tarefas consideradas, bem como a estabilidade do modelo sob diferentes regimes de mercado e cenários de *drift* temporal.

- **Atividade 7 – Análise de explicabilidade:** Investigação da interpretabilidade do modelo multimodal por meio da análise dos pesos de atenção cruzada e de métodos pós-hoc. Essa etapa busca compreender quais textos e segmentos temporais exercem maior influência nas predições, produzindo análises qualitativas e visualizações interpretáveis.
- **Atividade 8 – Consolidação e redação dos resultados:** Organização final dos experimentos, sistematização dos resultados obtidos e redação do relatório final de Iniciação Científica ou de um artigo acadêmico. O código será revisado e documentado, garantindo clareza metodológica e reprodutibilidade.

Tabela 1: Cronograma de atividades



7 Resultados Esperados

Espera-se que o modelo multimodal proposto apresente desempenho preditivo superior aos modelos unimodais de referência, especialmente em cenários nos quais eventos textuais relevantes antecedem ou acompanham mudanças significativas na dinâmica das séries temporais financeiras. A fusão latente profunda entre representações textuais e temporais deve resultar em ganhos consistentes em métricas de regressão ou classificação, além de maior estabilidade do desempenho ao longo do tempo, indicando maior robustez frente a drift temporal e mudanças de regime de mercado.

Adicionalmente, espera-se que os mecanismos de atenção cruzada possibilitem uma análise interpretável das predições, permitindo identificar quais textos e quais segmentos temporais tiveram maior influência nas decisões do modelo. Como resultado, o projeto deverá produzir evidências empíricas de que a integração explícita entre narrativa financeira e dinâmica quantitativa não apenas melhora a acurácia preditiva, mas também contribui para maior transparência e compreensão do processo decisório em modelos de predição financeira.

Referências

- [1] Z. Dong et al., *FNSPID: Financial News and Stock Price Integration Dataset*, GitHub, 2024.
- [2] W. Wenyan et al., *FinMultiTime: A Four-Modal Dataset for Financial Time-Series Analysis*, arXiv preprint arXiv:2506.05019, 2025.